

// EXAMEN DE GRADO 2025

Web Scraping y Ciberseguridad en el Retail

Análisis Ético, Técnico y Legal en Latinoamérica

Juan Arturo Rochat Sandoval

Ingeniería en Informática

El Desafío Central

El crecimiento exponencial del Web Scraping en el sector retail chileno carece de un marco técnico y legal estandarizado, generando vulnerabilidades críticas.

⚠ Riesgos Técnicos

- 🖨 Sobrecarga de infraestructura crítica y lentitud de servicios.
- 🛡 Vulneración de perímetros de seguridad (WAF, Firewalls).
- 👤 Exposición involuntaria de bases de datos internas.

⚖ Marco Normativo

- 📌 **Ley 21.663:** Ciberseguridad e Infraestructura Crítica.
- 🛡 **Ley 21.719:** Nueva Agencia de Protección de Datos.
- 🌐 **GDPR (UE):** Estándar internacional de privacidad.

Objetivos de la Investigación

Objetivo General: Desarrollar y validar una solución tecnológica ética, técnica y legalmente adecuada para realizar Web Scraping seguro.



Identificar

Identificar los marcos normativos aplicables en Latinoamérica y estándares internacionales.



Estructurar

Estructurar los requerimientos técnicos y éticos del Web Scraping en plataformas comerciales.



Diseñar

Diseñar e implementar una solución tecnológica integral bajo estándares de ciberseguridad.



Evaluar

Evaluar mediante pruebas rigurosas la eficacia técnica y normativa de la solución.

Marco Metodológico

Enfoque mixto (cualitativo y cuantitativo) orientado a generar una solución técnica basada en evidencia empírica.

 **Población y Muestra:** 50 expertos en ciberseguridad y TI del retail chileno (Muestreo dirigido).

 **Instrumento Cuantitativo:** Encuestas estructuradas (Google Forms) para medir percepción ética y brechas técnicas.

 **Técnica Cualitativa:** Análisis documental exhaustivo de leyes locales (21.663) y normativas internacionales.

 **Hallazgo Clave:** 70% cree que el scraping vulnera la seguridad, pero solo el 30% tiene protección activa.

¿Su empresa está protegida?

30% SÍ

50% NO

20% NS

Evidencia de la falta de estandarización técnica en la industria.

Flujo Lógico del Sistema (Workflow)

Proceso automatizado con controles éticos (robots.txt) integrados en el pipeline.

2. Verificación Ética

Lectura de `robots.txt`. Si el sitio bloquea el scraping, el proceso se aborta.

4. Procesamiento

Normalización de datos en el Backend (Java Spring Boot).
Limpieza de ruido HTML.

1. Autenticación

Login seguro vía OAuth 2.0 (API REST). Validación de permisos de usuario.

3. Extracción (Scraping)

Uso de Python (BeautifulSoup/Selenium) con control de latencia para no saturar.

5. Almacenamiento

Caché en Redis (rápido acceso) y persistencia segura en MongoDB.

| Arquitectura y Desarrollo Backend

El núcleo del sistema fue desarrollado aplicando el principio de **Seguridad desde el Diseño**.

 **Motores de Extracción:** Scripts en Python implementando *rate-limiting* para evitar bloqueos.

 **Backend Core:** API RESTful robusta construida con Java Spring Boot.

 **Infraestructura:** Despliegue en AWS utilizando Elastic Load Balancer (ELB) para alta disponibilidad.


 **Ciberseguridad:** Tokens JWT, encriptación SSL/TLS y mitigación de inyecciones SQL.

 Código Python BeautifulSoup


Interfaz de Administración

La solución cuenta con un panel centralizado que permite a los analistas de seguridad y operadores monitorear las tareas de extracción en tiempo real.

- ✓ **Monitoreo de APIs:** Estado de las peticiones REST.
- ✓ **Alertas de Seguridad:** Detección de bloqueos o CAPTCHAs.
- ✓ **Gestión de Carga:** Control de hilos simultáneos.



Almacenamiento NoSQL y Caché




Gestión de Datos Escalar

Para manejar el alto volumen de datos extraídos (precios, descripciones, stock) se implementó una arquitectura de doble capa:

-  **MongoDB:** Actúa como el repositorio principal (Data Lake). Su esquema flexible (NoSQL) permite almacenar estructuras JSON variables provenientes de distintos retailers sin romper la base de datos.
-  **Redis (In-Memory):** Implementado tras detectar cuellos de botella en la fase de pruebas. Actúa como caché temporal, reduciendo la latencia de lectura de la API en un 40%.


Aseguramiento de Calidad (QA) y Testing

Ejecución de pruebas estáticas (código) y dinámicas (integración) para garantizar fiabilidad.



Pruebas Estáticas (SonarQube)

Detección temprana de vulnerabilidades (Inyección de código), deuda técnica y cumplimiento de estándares de codificación segura antes del despliegue.



Pruebas Dinámicas (Postman)

Validación de endpoints REST (GET/POST), respuesta de tokens OAuth 2.0 y simulación de carga concurrente. Se utilizó PyTest y JUnit para pruebas unitarias.

Conclusiones de la Implementación



Eficacia Técnica

El sistema superó las pruebas de carga (resolviendo el fallo inicial CP-03) gracias a la implementación de balanceo en AWS y caché con Redis.



Cumplimiento Legal

La validación estricta del archivo `robots.txt` y la seguridad perimetral aseguran el respeto a la Ley 21.663 y estándares GDPR.



Impacto en la Industria

Se demostró que es posible realizar inteligencia de mercado competitiva sin comprometer la infraestructura crítica de terceros.

Referencias Bibliográficas (APA 7.0)

Entidad / Autor	Año	Título del Documento	Fuente
Gobierno de Chile	2024	Ley 21.663 Marco sobre Ciberseguridad e Infraestructura Crítica	Biblioteca del Congreso Nacional. www.bcn.cl/leychile
Gobierno de Chile	2024	Ley 21.719 Protección de Datos Personales	Biblioteca del Congreso Nacional. www.bcn.cl/leychile
Unión Europea	2018	Reglamento General de Protección de Datos (GDPR)	Diario Oficial de la Unión Europea. eur-lex.europa.eu
Banco Interamericano de Desarrollo (BID)	2020	Ciberseguridad: Riesgos, Avances y Camino a Seguir en LATAM	Observatorio de Ciberseguridad.
Mitchell, R.	2018	Web Scraping with Python: Collecting More Data from the Modern Web	O'Reilly Media, Inc.

¿Preguntas?

Muchas gracias por su atención e invaluable feedback durante este proceso.

 **DEMOSTRACIÓN EN VIVO DEL SISTEMA**

Image Sources



https://static.zenrows.com/content/large_scrapingcourse_product_description_inspection_218f267033.jpg

Source: www.zenrows.com



<https://cdn.dribbble.com/userupload/44075575/file/original-c347f3abbb947b6bf51671f43f83f8c7.webp?resize=752x&vertical=center>

Source: dribbble.com



<https://i.sstatic.net/6kfnd.png>

Source: stackoverflow.com



<https://i.sstatic.net/Llhr9.png>

Source: stackoverflow.com



<https://blog.postman.com/wp-content/uploads/2023/01/image9-1-1000x641.png>

Source: blog.postman.com