

Proyecto de Título: Web Scraping y Ciberseguridad

Candidato: Juan Arturo Rochat Sandoval

Objetivo del Documento: Consolidación de feedback académico, estrategia de defensa y especificaciones de arquitectura de software para generación automatizada de código.

1. Análisis Crítico del Feedback Docente

La revisión académica exige demostrar la funcionalidad práctica y la correcta interconexión de los componentes teóricos. Las acciones correctivas requeridas son:

- **Evidencia de Funcionalidad:** Es mandatorio presentar el código ejecutándose, capturas de pruebas estáticas/dinámicas y visualización de la base de datos con los datos extraídos.
- **Ajuste Metodológico:** Los objetivos específicos deben utilizar verbos de ingeniería (diseñar, implementar, evaluar).
- **Arquitectura y Flujos:** Se deben incorporar diagramas claros de la interconexión entre el código, la infraestructura y el cumplimiento legal.

2. Especificaciones de Ingeniería para Desarrollo (Prompt)

El siguiente bloque contiene las directrices arquitectónicas para inicializar el proyecto mediante asistencia de IA (Claude Code / Antigravity). Está diseñado para generar una Prueba de Concepto (PoC) sólida y defendible.

Rol: Ingeniero de Software Senior y Arquitecto de Ciberseguridad.
Contexto: Desarrollo urgente de un sistema de Web Scraping para e-commerce que cumpla con normativas de ciberseguridad, diseñado como prueba de concepto para una tesis de ingeniería informática. El objetivo es demostrar un flujo completo de extracción, almacenamiento seguro y API de consumo.

Stack Tecnológico Requerido:

- Backend / API Gateway: Java Spring Boot.
- Motor de Scraping: Python (BeautifulSoup para parseo rápido, Selenium para

contenido dinámico).

- Base de Datos: MongoDB (almacenamiento de catálogos JSON).
- Caché y Sesiones: Redis.
- Testing: Configuración base para SonarQube (calidad estática) y endpoints para pruebas en Postman.

Requerimientos Arquitectónicos y Funcionales:

1. Lógica de Extracción (Crawler): El script de Python debe estructurarse para navegar páginas de listas de productos (PLP) y extraer atributos clave (SKU, Nombre, Precio, URL).
2. Evasión y Seguridad: Implementar manejo de rotación de proxies y configuración de User-Agents para sortear bloqueos de seguridad tipo Cloudflare.
3. Cumplimiento Ético: El módulo debe incluir una función que valide el archivo robots.txt del dominio objetivo y aplique rate-limiting (retrasos entre peticiones) para evitar ataques de denegación de servicio (DDoS) involuntarios.
4. Interconexión: La API en Spring Boot debe tener un endpoint que inicie el proceso de Python y otro endpoint que consulte a MongoDB para devolver los datos extraídos.
5. Infraestructura Local: Generar un archivo docker-compose.yml que levante los servicios necesarios (MongoDB, Redis) para asegurar una ejecución rápida de la demostración.

Entregables Solicitados:

- Estructura completa del proyecto (/backend y /scraper).
- Código fuente funcional con comentarios técnicos.
- Archivo docker-compose.yml.
- Un README.md con el "Paso a Paso" exacto para compilar, levantar los contenedores, ejecutar el scraper y probar la API.